

Análisis Comparativo de Métodos de Extracción de Características y su Impacto en el Espacio de Características para la Clasificación de Imágenes.

1st Angelo Barbieri
dept. Ing. Eléctrica y Electrónica
Universidad del Bío Bío
Concepción, Chile

2nd Thomas Bustamante
dept. Ing. Eléctrica y Electrónica.
Universidad del Bío Bío.
Concepción, Chile.

3rd Edward Guzmán
dept. Ing. Eléctrica y Electrónica.
Universidad del Bío Bío.
Concepción, Chile.

Resumen—Este estudio se centra en el análisis comparativo de diferentes técnicas de extracción de características aplicadas a imágenes, tanto tradicionales como modernas, para determinar su impacto en el desempeño de los algoritmos de clasificación. Al aplicar algoritmos de clasificación de aprendizaje supervisado a las características extraídas, se busca identificar las combinaciones más efectivas para lograr una buena clasificación según las métricas de desempeño utilizadas. Además, de un análisis de la eficiencia computacional.

I. INTRODUCCIÓN

El procesamiento y la clasificación de imágenes son pilares fundamentales en áreas como la salud, la seguridad y los sistemas autónomos, donde las decisiones basadas en datos visuales tienen un impacto crítico. Los avances recientes en inteligencia artificial (IA) han proporcionado herramientas robustas para estas tareas, pero el éxito de estos modelos depende en gran medida de la calidad de las características extraídas y del preprocesamiento de los datos. Técnicas de extracción de características, tanto tradicionales como modernas, permiten identificar patrones significativos en los datos, mientras que los algoritmos de aprendizaje supervisado ofrecen capacidades avanzadas de clasificación y predicción.

El aprendizaje supervisado ha sido una herramienta fundamental para la clasificación de datos, permitiendo que los algoritmos aprendan patrones a partir de ejemplos etiquetados. Métodos tradicionales como las Máquinas de Soporte Vectorial (*SVM*) y Árboles de Decisión han sido populares por su capacidad para generalizar en problemas de clasificación con datos estructurados [1], [2]. Sin embargo, el rendimiento de estos algoritmos depende en gran medida de la calidad del espacio de características, que debe capturar adecuadamente la variabilidad y las relaciones en los datos.

La extracción de características es el proceso clave para construir este espacio. Desde enfoques clásicos como *SIFT* y *HOG*, que se enfocan en características locales y globales en imágenes, hasta métodos modernos basados en redes neuronales, como las Redes Neuronales Convolucionales (*CNNs*) y *autoencoders*, que aprenden representaciones

complejas directamente de los datos [3]–[6]. Recientemente, los modelos basados en atención, como los *transformers*, han mostrado un rendimiento sobresaliente en la extracción de características de alto nivel, mejorando significativamente la capacidad de los modelos para clasificar datos complejos de manera más eficiente [7].

A. Objetivos

- Analizar el impacto de diferentes técnicas de extracción de características tanto tradicionales como modernas en la calidad del espacio de características para la clasificación de imágenes.
- Evaluar cómo la calidad de las características extraídas influye en la capacidad de los clasificadores.
- Analizar la relación entre la complejidad de las técnicas de extracción de características y la eficiencia computacional en tareas de clasificación.

II. FORMULACIÓN DEL PROBLEMA

Seleccionar el método adecuado para la extracción de características en clasificación supervisada sigue siendo un reto. Aunque los métodos modernos, como las redes neuronales profundas, han demostrado ser efectivos, los enfoques tradicionales siguen siendo competitivos, especialmente en contextos con recursos limitados o datos simples.

La calidad de las características extraídas impacta directamente en el rendimiento de los clasificadores, por lo que es crucial elegir la técnica más adecuada. Este estudio se plantea comparar el impacto de los métodos tradicionales y modernos de extracción de características en el rendimiento de clasificadores estándar, evaluando diferencias en términos de desempeño y eficiencia computacional. La meta es proporcionar una guía sobre qué enfoque utilizar en función del contexto y los recursos disponibles.

III. MATERIALES Y MÉTODO

Se trabajará con conjuntos de imágenes etiquetadas de fuente abierta. Uno de los conjuntos es *Fashion MNIST*,

este posee 60000 imágenes en escala de grises de 28×28 , correspondientes a distintas prendas de vestir, sus clases (10000 imágenes por clases) son: *T-shirt/top*, *Trouser*, *Pullover*, *Dress*, *Coat*, *Sandal*, *Shirt*, *Sneaker*, *Bag*, *Ankle boot*. La figura 1 muestra algunas imágenes de *Fashion MNIST* [8].

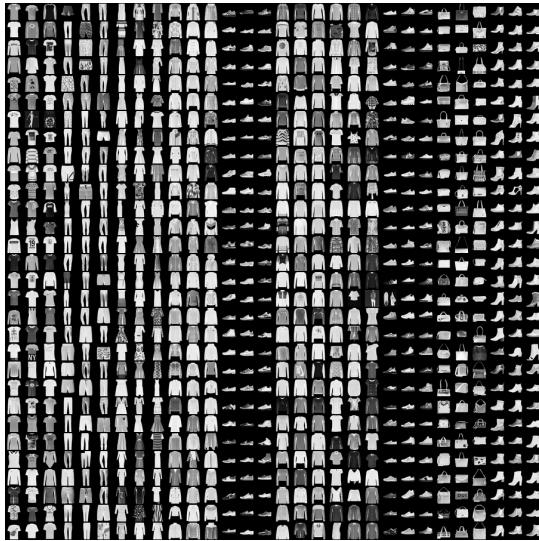


Fig. 1. Imágenes en *Fashion MNIST*. Fuente: Adaptado de [8].

También, se utilizará *CIFAR-10*. Al igual que *Fashion MNIST* este conjunto tiene 10 clases, con 10000 imágenes por cada clase, es decir, un total de 60000 imágenes. Las clases del conjunto son: *airplane*, *automobile*, *bird*, *cat*, *deer*, *dog*, *frog*, *horse*, *ship*, *truck*. Cada imagen es de 3 canales y tiene dimensiones 32×32 . La figura 2 muestra imágenes pertenecientes a *CIFAR-10* [9].

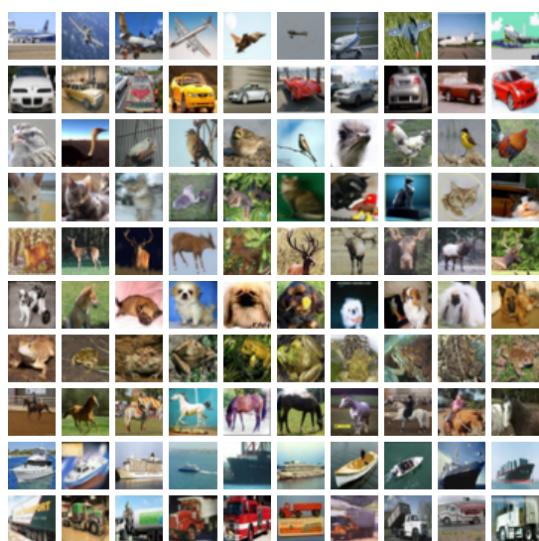


Fig. 2. Imágenes de *CIFAR-10*. Fuente: Adaptado de [9].

La metodología propuesta para este proyecto tiene como objetivo comparar la calidad de las características extraídas por diferentes métodos, tanto tradicionales como modernos, en el contexto de tareas de clasificación. Se llevará a cabo un análisis exhaustivo que abarca desde la selección del conjunto de datos y el preprocesamiento de las imágenes, hasta la evaluación de los resultados obtenidos mediante clasificadores. A continuación, se detallan las fases principales de la metodología que guiarán el desarrollo del estudio.

- **Selección del Conjunto de Datos:** Elección de datasets para tareas de clasificación.
- **Preprocesamiento de Datos:** Preprocesamiento según los métodos de extracción.
- **Métodos de Extracción de Características:** Implementación de métodos tradicionales y modernos para la extracción de características.
- **Clasificación:** Evaluación de las características extraídas mediante clasificadores.
- **Evaluación y Comparación:** Comparación de los resultados de clasificación (métricas de desempeño) y análisis computacional. Incluye validación cruzada para asegurar la fiabilidad de los resultados.
- **Discusión de Resultados:** Análisis de la calidad discriminativa de las características extraídas.
- **Conclusiones y Recomendaciones:** Resumen de los hallazgos y recomendaciones sobre los métodos de extracción más eficaces.

IV. CONCLUSIÓN

Este análisis comparativo se plantea con el objetivo de comprender cómo diferentes técnicas de extracción de características impactan el rendimiento de los algoritmos de clasificación de imágenes. A pesar de los avances con métodos modernos, se busca evaluar si las técnicas tradicionales siguen siendo competitivas en ciertos escenarios.

REFERENCIAS

- [1] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [2] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [3] D. Lowe, “Distinctive image features from scale-invariant keypoints,” *International Journal of Computer Vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [4] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *IEEE Conference on Computer Vision and Pattern Recognition*, 2005.
- [5] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, pp. 436–444, 2015.
- [6] G. E. Hinton and R. R. Salakhutdinov, “Reducing the dimensionality of data with neural networks,” *Science*, vol. 313, no. 5786, pp. 504–507, 2006.
- [7] N. Vaswani et al., “Attention is all you need,” in *Neural Information Processing Systems (NeurIPS)*, 2017.
- [8] H. Xiao, K. Rasul, and R. Vollgraf, “Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms,” Aug. 28, 2017. [Online]. Available: arXiv:cs.LG/1708.07747.
- [9] A. Krizhevsky, “Learning multiple layers of features from tiny images,” University of Toronto, Technical Report, 2009. [Online]. Available: <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>.