

Análisis Comparativo de Métodos de Extracción de Características y su Impacto en el Espacio de Características para la Clasificación de Imágenes.

1st Angelo Barbieri
dept. Ing. Eléctrica y Electrónica
Universidad del Bío Bío
Concepción, Chile

2nd Thomas Bustamante
dept. Ing. Eléctrica y Electrónica.
Universidad del Bío Bío.
Concepción, Chile.

3rd Edward Guzmán
dept. Ing. Eléctrica y Electrónica.
Universidad del Bío Bío.
Concepción, Chile.

Resumen—La extracción de características es fundamental en la clasificación de imágenes, impactando directamente el desempeño de los algoritmos de aprendizaje supervisado. Este estudio analiza técnicas tradicionales como *BoVW* basado en *SIFT*, junto con métodos modernos representados por *CNNs* como *ResNet50*, evaluando su efectividad en conjuntos de datos como *Fashion MNIST* y *CIFAR-10*. Se aplicaron clasificadores como *Random Forest* y *MLP* para medir la calidad de las características extraídas y se analizó el tiempo de ejecución de los métodos evaluados. Los resultados muestran que los métodos tradicionales pierden efectividad con datos complejos, mientras que los modernos mantienen un alto desempeño. Este trabajo ofrece guías prácticas para elegir técnicas según los datos y métodos.

Palabras clave—*BoVW* (Bolsa de Palabras Visuales), *CNN* (Red Neuronal Convolucional). Clasificación de imágenes, Extracción de características.

I. INTRODUCCIÓN

El procesamiento y la clasificación de imágenes son pilares fundamentales en áreas como la salud, la seguridad y los sistemas autónomos, donde las decisiones basadas en datos visuales tienen un impacto crítico. Los avances recientes en inteligencia artificial (IA) han proporcionado herramientas robustas para estas tareas, pero el éxito de estos modelos depende en gran medida de la calidad de las características extraídas y del preprocesamiento de los datos. Técnicas de extracción de características, tanto tradicionales como modernas, permiten identificar patrones significativos en los datos, mientras que los algoritmos de aprendizaje supervisado ofrecen capacidades avanzadas de clasificación y predicción.

El aprendizaje supervisado ha sido una herramienta fundamental para la clasificación de datos, permitiendo que los algoritmos aprendan patrones a partir de ejemplos etiquetados. Métodos tradicionales como las Máquinas de Soporte Vectorial (SVM) y Árboles de Decisión han sido populares por su capacidad para generalizar en problemas de clasificación con datos estructurados [1], [2]. Sin embargo, el rendimiento de estos algoritmos depende en gran medida de la calidad del espacio de características, que debe capturar

adecuadamente la variabilidad y las relaciones en los datos.

La extracción de características es el proceso clave para construir este espacio. Desde enfoques clásicos como la técnica de Bolsa de Palabras Visuales (*BoVW*), basada en descriptores como *SIFT* y *HOG*, que se enfocan en características locales y globales en imágenes, hasta métodos modernos basados en redes neuronales, como las Redes Neuronales Convolucionales (*CNNs*) y *autoencoders*, que aprenden representaciones complejas directamente de los datos [3]–[7]. Recientemente, los modelos basados en atención, como los *transformers*, han mostrado un rendimiento sobresaliente en la extracción de características de alto nivel, mejorando significativamente la capacidad de los modelos para clasificar datos complejos de manera más eficiente [8].

Para evaluar y comparar las técnicas de extracción de características, este trabajo emplea dos conjuntos de datos de imágenes con diferentes niveles de complejidad. *Fashion MNIST* es un conjunto ampliamente utilizado en la investigación de aprendizaje automático, compuesto por imágenes en escala de grises de 28×28 píxeles que representan categorías de ropa y accesorios [9]. Su simplicidad lo convierte en un punto de partida para probar técnicas de clasificación y extracción de características. Por otro lado, *CIFAR-10* presenta un desafío mayor al incluir imágenes a color de 32×32 píxeles que abarcan una mayor diversidad de clases, como animales y vehículos [10]. Estas diferencias permiten analizar cómo las técnicas de extracción y clasificación se desempeñan en distintos escenarios.

El análisis se estructura en varias etapas: (1) selección y preprocesamiento de los datos, (2) aplicación de técnicas tradicionales como *BoVW* y modernas representadas por *CNNs* como *ResNet50* para la extracción de características, (3) clasificación de los vectores de características mediante algoritmos supervisados como *Random Forest* y *Multi-Layer Perceptron* (MLP), y (4) evaluación y comparación del desempeño en función de métricas. Este trabajo analiza diferentes perspectivas, destacando cómo la complejidad de

los datos afecta el rendimiento de los clasificadores y la representación de las características.

El resto del documento se estructura de la siguiente manera: la Sección II detalla los métodos y configuraciones experimentales, la Sección III presenta los resultados obtenidos, y la Sección IV resume las conclusiones y propuestas para trabajos futuros.

II. MATERIALES Y MÉTODO

En esta sección, se describe el conjunto de datos utilizado, los métodos de extracción de características y los algoritmos de clasificación empleados, así como las configuraciones específicas de los experimentos realizados para evaluar el rendimiento de los métodos.

A. Conjuntos de Datos

Se utilizaron dos conjuntos de datos de fuente abierta para la evaluación: *Fashion MNIST* y *CIFAR-10*. Cada uno de estos posee 10 clases. Para reducir la complejidad computacional, se seleccionó un subconjunto de 5000 imágenes por dataset (500 imágenes por clase).

Fashion MNIST posee 70000 imágenes en escala de grises de 28×28 píxeles, correspondientes a distintas prendas de vestir, sus clases (7000 imágenes por clase) son: *T-shirt/top*, *Trouser*, *Pullover*, *Dress*, *Coat*, *Sandal*, *Shirt*, *Sneaker*, *Bag*, *Ankle boot* [9]. La figura 1 muestra algunas imágenes de *Fashion MNIST*.




Fig. 1: Imágenes en *Fashion MNIST*. Fuente: Adaptado de [9].

CIFAR-10 tiene 10 clases, con 6000 imágenes por cada clase, es decir, un total de 60000 imágenes. Las clases del conjunto son: *airplane*, *automobile*, *bird*, *cat*, *deer*, *dog*, *frog*, *horse*, *ship*, *truck*. Cada imagen es de 3 canales y tiene

dimensiones 32×32 [10]. La figura 2 muestra imágenes pertenecientes a *CIFAR-10*.




Fig. 2: Imágenes de *CIFAR-10*. Fuente: Adaptado de [10].

B. Metodología

La metodología propuesta para este proyecto tiene como objetivo comparar la calidad de las características extraídas por diferentes métodos, tanto tradicionales como modernos, en el contexto de tareas de clasificación. Para lograr esto, se definieron las siguientes etapas principales:

- **Selección de Datos:** Identificación y selección de los conjuntos de datos relevantes para el estudio.
- **Preprocesamiento:** Transformación y normalización de los datos para adaptarlos a los requerimientos de los métodos de extracción y clasificación.
- **Extracción de Características:** Aplicación de métodos tradicionales y modernos para obtener representaciones de las imágenes.
- **Clasificación:** Evaluación de las características extraídas mediante algoritmos supervisados.
- **Evaluación:** Análisis de los resultados obtenidos en términos de métricas de desempeño.

A continuación, se describen los métodos utilizados para la extracción de características, destacando sus principales características y la forma en que fueron implementados en este estudio:

SIFT: Es un método tradicional de extracción de características basado en la detección y descripción de puntos clave. Este algoritmo es robusto a cambios de escala y rotación, lo que lo hace ideal para análisis de imágenes con variaciones en la perspectiva o iluminación [3]. Los pasos principales incluyen: (1) detección de puntos clave mediante

diferencias de escala, (2) descripción de los puntos clave a través de histogramas de gradientes, y (3) construcción de un modelo *Bolsa de Palabras Visuales (BoVW)* para representar las imágenes.

En este estudio, se utiliza la implementación de *SIFT* provista por *OpenCV*, con parámetros predeterminados para la detección de puntos clave. Para construir el *BoVW*, se aplica el algoritmo *K-Means* con 100 clústeres, es utilizada la implementación de *Scikit-learn*.

La figura 3 muestra los puntos clave de una imagen de *CIFAR-10* obtenidos con *SIFT*.



Fig. 3: a) Imagen de *CIFAR-10*. b) Puntos clave obtenidos mediante *SIFT* sobre la misma imagen de *CIFAR-10*. Fuente: Elaboración propia.

ResNet50: Es una red convolucional profunda. Utiliza normalización por lotes para mitigar el sobreajuste y módulos residuales con conexiones de salto para facilitar el aprendizaje en capas profundas, superando el problema del desvanecimiento del gradiente [11]. La implementación se lleva a cabo mediante *TensorFlow/Keras*.

Para la clasificación, se utilizaron dos algoritmos supervisados: *Random Forest (RF)* y *Multi-Layer Perceptron (MLP)*. *Random Forest* es un conjunto de árboles de decisión que combina sus predicciones para mejorar la precisión y reducir el riesgo de sobreajuste [12]. En este estudio, fue implementado usando la implementación de *Scikit-learn*, se configuró con 500 estimadores ($n_{estimators}$) y criterio *gini*. Por otro lado, *MLP* es una red neuronal completamente conectada [13]. En este caso, incluye una capa oculta de 256 neuronas con activación *ReLU* y una capa de salida con activación *softmax*, implementada en *Tensorflow/Keras*.

C. Configuraciones Experimentales

Para evaluar el desempeño de los métodos tradicionales como *BoVW* y modernos representados por *CNNs* como *ResNet50*, se llevaron a cabo diversos experimentos bajo las siguientes configuraciones:

1) *Experimentos con BoVW (SIFT):* Se realizaron experimentos con 10 y 2 clases de cada dataset:

- **10 clases:** Las imágenes fueron redimensionadas a 224×224 píxeles, y las de *CIFAR-10* fueron convertidas a escala de grises antes del redimensionamiento. Se utilizó un modelo *BoVW*, basado en descriptores *SIFT* con su configuración por defecto en *OpenCV*, y 100 clústeres generados mediante *K-Means*.
- **2 clases:** Para reducir la complejidad del problema, se seleccionaron 2 clases de cada dataset, manteniendo las mismas configuraciones descritas anteriormente.

2) *Experimentos con ResNet50:* Se utilizaron dos configuraciones para evaluar el impacto del ajuste fino de los pesos en el extractor:

- **Congelado Total:** Las imágenes se redimensionaron a 224×224 píxeles y las de *Fashion MNIST* fueron convertidas a imágenes a color. Se utilizó un modelo preentrenado en *ImageNet* [14], congelando completamente las capas convolucionales. Además, se aplicó la función de preprocesamiento específica de *Keras* para *ResNet*.
- **Congelado Parcial:** Se permitió el ajuste fino del último bloque de capas convolucionales de *ResNet50* (ver figura 4). El modelo incluyó una capa de salida adaptada a los datos utilizados y se entrenó con los siguientes hiperparámetros: optimizador *Adam*, tasa de aprendizaje de 0.001, función de pérdida *Categorical Cross-Entropy*, tamaño de batch de 32, y un máximo de 50 épocas. Se utilizó validación cruzada estratificada con $k = 5$, reservando un 20% de los datos de entrenamiento para validación interna. El entrenamiento implementó un criterio de detención temprana basado en el error de validación (*val_loss*) con una paciencia de 10 épocas. Los pesos seleccionados fueron aquellos que lograron el mejor promedio de *accuracy* y *F1 ponderado* en las iteraciones de validación cruzada.

	layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
No Entrenable	conv1	112×112	7×7, 64, stride 2				
			3×3 max pool, stride 2				
	conv2.x	56×56	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix} \times 3$
	conv3.x	28×28	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix} \times 8$
	conv4.x	14×14	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix} \times 36$
Entrenable	conv5.x	7×7	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix} \times 3$	
	Softmax						

Fig. 4: Capas congeladas de *ResNet50*. Fuente: Adaptado de [11].

Como se menciona, los preprocesamientos realizados consisten principalmente en redimensionamiento y

conversión de escala; esto fue realizado utilizando las funciones *smart_resize* de *Keras* y *cvtColor* de *OpenCV*, respectivamente.

3) *Algoritmos de Clasificación*: Los clasificadores *Random Forest* y *Multi-Layer Perceptron (MLP)* fueron utilizados para evaluar las características extraídas:

- **Random Forest**: Se configuró con 500 estimadores (*n_estimators*) y el criterio *gini*.
- **MLP**: Incluyó una capa oculta de 256 neuronas con activación *ReLU* seguida de una capa de salida con activación *softmax*. El entrenamiento utilizó el optimizador *Adam* con una tasa de aprendizaje de 0.001, la función de pérdida *Categorical Cross-Entropy*, un tamaño de *batch* de 32, un máximo de 50 épocas, y criterio de detención temprana basado en el error de validación (*val_loss*) con una paciencia de 10 épocas. También se empleó validación cruzada estratificada con $k = 5$, reservando un 20% de los datos de entrenamiento para validación.

El desempeño de los métodos y clasificadores fue evaluado utilizando *accuracy* y *F1 ponderado*. Estas métricas permitieron analizar la calidad discriminativa de las características extraídas y su impacto en el desempeño de los clasificadores.

Dada la complejidad computacional de los algoritmos, para los códigos que utilizan *SIFT* se utilizó una *CPU Intel Xeon* y para los códigos que involucran *ResNet50* se utilizó una *GPU Tesla T4* con *High-RAM*. Estos recursos fueron utilizados desde la plataforma *Google Colab*.

III. RESULTADOS

En esta sección, se presentan los resultados del análisis de los métodos de extracción de características y clasificadores aplicados a los conjuntos de datos *Fashion MNIST* y *CIFAR-10*. Se evalúa el desempeño en términos de *accuracy* y *F1 ponderado*. Los resultados se resumen en la Tabla 1.

En términos de rendimiento, el mejor resultado se obtuvo utilizando *ResNet50* en modo de congelamiento parcial combinado con el clasificador *MLP*, alcanzando un *accuracy* del 98.3% y un *F1 ponderado* del 98.3% en *Fashion MNIST*, y un *accuracy* del 97.5% y un *F1 ponderado* del 97.5% en *CIFAR-10*. Este resultado resalta la capacidad de las características extraídas por métodos modernos para capturar patrones complejos en los datos.

Por otro lado, el peor desempeño fue observado al utilizar *SIFT* combinado con *MLP* en el conjunto de datos *CIFAR-10* con 10 clases, con un *accuracy* de tan solo 26.7% y un *F1 ponderado* de 25.8%. Este resultado refleja las limitaciones de las técnicas tradicionales de extracción de características al enfrentar datos más complejos.

En general, los resultados sugieren que los métodos modernos como *ResNet50*, especialmente con configuraciones de ajuste fino (congelamiento parcial), ofrecen un desempeño superior en tareas de clasificación de imágenes, particularmente en conjuntos de datos con mayor complejidad.

La Tabla 2, se presentan los tiempos de ejecución de los métodos de extracción de características utilizados en este estudio. Estos tiempos corresponden a las configuraciones evaluadas tanto para *Fashion MNIST* como para *CIFAR-10*. El objetivo de este análisis es comparar la eficiencia computacional de los métodos tradicionales como *SIFT* frente a las técnicas modernas basadas en *Deep Learning*, como *ResNet50*, bajo diferentes configuraciones experimentales.

Los resultados muestran que el tiempo de ejecución varía significativamente según el método empleado y la complejidad del conjunto de datos. En general, *BoVW (SIFT)* presentó tiempos de ejecución más cortos en configuraciones con menos clases (2 clases), mientras que *CNN (ResNet50)*, especialmente en el modo de congelamiento parcial, requirió considerablemente más tiempo debido al proceso de ajuste fino.

Tabla 1: Resultados de desempeño de los clasificadores con características extraídas mediante *BoVW (SIFT)* y *ResNet50*. Fuente: Elaboración Propia.

Método de Extracción + Clasificador	Configuración	Accuracy (%)		F1 Ponderado (%)	
		Fashion MNIST	CIFAR-10	Fashion MNIST	CIFAR-10
BoVW (SIFT) + RF	10 Clases	61.8	28.3	60.6	27.5
	2 Clases	95.0	80.0	94.9	79.9
BoVW (SIFT) + MLP	10 Clases	61.1	26.7	60.6	25.8
	2 Clases	94.7	50.2	94.6	33.7
CNN (ResNet50) (Congelado Total) + RF	10 Clases	85.1	84.6	84.8	84.5
CNN (ResNet50) (Congelado Total) + MLP	10 Clases	86.2	86.2	86.0	86.2
CNN (ResNet50) (Congelado Parcial) + RF	10 Clases	98.2	97.1	98.2	97.1
CNN (ResNet50) (Congelado Parcial) + MLP	10 Clases	98.3	97.5	98.3	97.5

Tabla 2: Tiempo de ejecución de los métodos de extracción de características. Fuente: Elaboración Propia.

Método de Extracción	Tiempo de Ejecución (s)	
	Fashion MNIST	CIFAR-10
BoVW (SIFT) (10 clases)	185.0499	232.7880
BoVW (SIFT) (2 clases)	33.0705	38.3946
CNN (ResNet50) (Congelado Total)	31.6223	30.6810
CNN (ResNet50) (Congelado Parcial)	1433.7063	1566.5087

IV. CONCLUSIONES

En este trabajo, se evaluaron métodos tradicionales y modernos de extracción de características y clasificadores aplicados a *Fashion MNIST* y *CIFAR-10*, analizando su desempeño en términos de *accuracy* y *F1 ponderado*. Los resultados destacan la efectividad de los enfoques modernos frente a los tradicionales, así como la influencia de la complejidad de los datos y las configuraciones experimentales. A continuación, se presentan las principales conclusiones y propuestas para trabajos futuros.

- Los desempeños en *Fashion MNIST* son superiores a los de *CIFAR-10*, lo que refleja la menor complejidad de *Fashion MNIST*, compuesto por imágenes en escala de grises y menor dimensionalidad, frente a *CIFAR-10*, que contiene imágenes a color y de mayor resolución. Además, al convertir las imágenes de *CIFAR-10* a escala de grises para utilizar *SIFT*, se pierde información clave relacionada con el color, lo que impacta negativamente el rendimiento de los clasificadores en este conjunto de datos.
- Los métodos modernos como *ResNet50* demostraron una clara superioridad sobre los métodos tradicionales, logrando excelentes resultados incluso con las 10 clases, especialmente cuando se aplica ajuste fino. Aunque el desempeño fue ligeramente mejor en *Fashion MNIST*, los resultados en *CIFAR-10* también fueron muy buenos, destacando su capacidad para manejar datos más complejos con solo una pequeña disminución en el rendimiento. Sin embargo, para problemas menos complejos, como *Fashion MNIST* con 2 clases, *SIFT* logró métricas altas de *accuracy* y *F1 ponderado*, lo que sugiere que métodos tradicionales como *SIFT* pueden ser una opción adecuada, considerando su buen desempeño en estas configuraciones y su menor tiempo de ejecución.
- Como trabajo futuro, se podría explorar el uso de *SIFT* directamente con las imágenes de *CIFAR-10* a color, evitando así la pérdida de información asociada a la conversión a escala de grises. Además, sería interesante investigar otras técnicas de clustering más allá de *K-Means*, con el objetivo de construir palabras visuales más representativas. Por otro lado, tanto en métodos tradicionales como modernos, se podrían evaluar alternativas como *HoG* y *LBP* en el caso de técnicas tradicionales, o

explorar el uso de *autoencoders*, redes neuronales con mecanismos de atención, o incluso otras arquitecturas *CNNs*, ampliando así el análisis comparativo

REFERENCIAS

- [1] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [2] L. Breiman, "Random forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [3] D. Lowe, "Distinctive image features from scale-invariant keypoints," *International Journal of Computer Vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [4] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2005.
- [5] Csurka, Gabriella, et al. "Visual categorization with bags of keypoints." Workshop on statistical learning in computer vision, ECCV. Vol. 1. No. 1–22. 2004.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436–444, 2015.
- [7] G. E. Hinton and R. R. Salakhutdinov, "Reducing the dimensionality of data with neural networks," *Science*, vol. 313, no. 5786, pp. 504–507, 2006.
- [8] N. Vaswani et al., "Attention is all you need," in *Neural Information Processing Systems (NeurIPS)*, 2017.
- [9] H. Xiao, K. Rasul, and R. Vollgraf, "Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms," Aug. 28, 2017. [Online]. Available: [arXiv:cs.LG/1708.07747](https://arxiv.org/abs/1708.07747).
- [10] A. Krizhevsky, "Learning multiple layers of features from tiny images," University of Toronto, Technical Report, 2009. [Online]. Available: <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR>.
- [11] He, Kaiming, et al. "Deep residual learning for image recognition." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [12] Parmar, Aakash, Rakesh Katariya, and Vatsal Patel. "A review on random forest: An ensemble classifier." International conference on intelligent data communication technologies and internet of things (ICICI) 2018. Springer International Publishing, 2019.
- [13] Y. Jusman, I. M. Firdiantika, D. A. Dharmawan and K. Purwanto, "Performance of Multi Layer Perceptron and Deep Neural Networks in Skin Cancer Classification," 2021 IEEE 3rd Global Conference on Life Sciences and Technologies (LifeTech), Nara, Japan, 2021, pp. 534–538, doi: 10.1109/LifeTech52111.2021.9391876.
- [14] Deng, Jia, et al. "Imagenet: A large-scale hierarchical image database." 2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009.